数据库

1.事务

1.1概念:

事务指的是满足 ACID 特性的一组操作,可以通过 Commit 提交一个事务,也可以使用 Rollback 进行回滚。

1.2ACID特性:

- (1) **原子性 (Atomicity)**: 事务被视为不可分割的**最小单元**,事务的所有操作要么全部**提交成功**,要么全部**失败回滚。**回滚可以用**回滚日志**来实现,回滚日志记录着事务所执行的**修改操作**,在回滚时反向执行这些修改操作即可。
- (2) **一致性 (Consistency)**: 数据库在事务执行前后都保持一致性状态。在一致性状态下,所有事务对一个数据的读取结果都是相同的。
- (3) 隔离性 (Isolation): 一个事务所做的修改在最终提交以前,对其它事务是不可见的。
- (4) **持久性 (Durability)**:一旦事务提交,则其所做的修改将会永远保存到数据库中。即使系统发生崩溃,事务执行的结果也不能丢失。

使用重做日志来保证持久性。

事务的 ACID 特性概念简单,但不是很好理解,主要是因为这几个特性不是一种平级关系:只有**满足一致性**,事务的执行结果才是**正确**的。

在**无并发**的情况下,事务**串行执行,隔离性**一定能够满足。此时只要能满足**原子性**,就一定能**满足一致性**。

在**并发**的情况下,多个事务**并行执行**,事务不仅要满足**原子性**,还需要满足**隔离性**,才能**满足一致性**。事务满足**持久性**是为了能应对**数据库崩溃**的情况。

2.并发一致性问题

2.1丢失数据

丢失数据: T_1 和 T_2 两个事务都对一个数据进行修改, T_1 先修改, T_2 随后修改, T_2 的修改覆盖了 T_1 的修改。简记为 同时修改。

2.2读脏数据

读脏数据: T_1 对一个数据做了修改, T_2 读取这一个数据。若 T_1 执行 ROLLBACK 操作,则 T_2 读取的结果和第一次的结果不一样。简记为 读取失败的修改。最简单的场景是修改完成后,紧接着查询检验结果。

2.3不可重复读

不可重复读: T_2 读取一个数据, T_1 对该数据做了修改。如果 T_2 再次读取这个数据, 此时读取的结果和第一次读取的结果不同。简记为 读时修改, 重复读取的结果不一样。

2.4幻影读

幻影读: T_1 读取某个范围的数据, T_2 在这个范围内插入新的数据, T_1 再次读取这个范围的数据, 此时读取的结果和和第一次读取的结果不同。简记为 读时插入,重复读取的结果不一样。

1.5解决方案

在并发环境下,事务的隔离性很难保证,因此会出现很多并发一致性问题。产生并发不一致性问题的**主要原因是破坏了事务的隔离**性。解决方法是通过 **并发控制** 来保证隔离性。并发控制可以通过 **封锁** 来实现,但是封锁操作需要用户自己控制,相当复杂。数据库管理系统提供了事务的 **隔离级别**,让用户以一种更轻松的方式处理并发一致性问题。

3.封锁

3.1封锁粒度

MySQL 中提供了两种封锁粒度: 行级锁 以及 表级锁。

应尽量只**锁定需要修改的那部分**数据,而不是所有的资源。锁定的数据量越少,发生锁争用的可能就越小,系统的并发程度就越高。但是加锁需要消耗资源,锁的各种操作(包括获取锁、释放锁、以及检查锁状态)都会增加系统开销。因此封锁粒度越小,系统开销就越大。为此,我们在选择封锁粒度时,需在**锁开销**和 **并发程度** 之间做一个 权衡。

3.2封锁类型

(1) 读写锁

排它锁 (Exclusive), 简写为 X 锁, 又称 写锁。

共享锁 (Shared), 简写为 S 锁, 又称 读锁。

有以下两个规定:

一个事务对数据对象 A 加了 X 锁,就可以对 A 进行**读取和更新**。加锁期间其它事务不能对 A 加任何 锁。

一个事务对数据对象 A 加了 S 锁,可以对 A 进行**读取**操作,但是不能进行更新操作。加锁期间其它事务能对 A 加 S 锁,但是不能加 X 锁。

(2) 意向锁

使用意向锁 (Intention Locks),可以更容易地支持**多粒度封锁**,使得**行锁和表锁能够共存**。 在存在行级锁和表级锁的情况下,事务 T 想要对表 A 加 X 锁,就需要先检测是否有其它事务对表 A 或 者表 A 中的任意一行加了锁,那么就需要对表 A 的每一行都检测一次,这是非常耗时的。

意向锁在原来的 X/S 锁之上引入了 IX / IS, IX / IS 都是 **表级别的锁**,用来表示一个事务**稍后**会对表中的某个**数据行上加 X 锁或 S 锁**。整理可得以下两个规定:

- 一个事务在获得某个数据行对象的 S 锁之前,必须先获得表的 **IS 锁或者更强的锁**;
- 一个事务在获得某个数据行对象的 X 锁之前, 必须先获得表的 IX 锁。

3.3封锁协议

三级封锁协议

一级封锁协议: 事务 T 要修改数据 A 时必须加 X 锁,直到 T 结束才释放锁。防止同时修改,可解决 **丢失修改** 问题,因不能同时有两个事务对同一个数据进行修改,那么事务的修改就不会被覆盖。

二级封锁协议:在一级的基础上,要求读取数据 A 时必须加 S 锁,读取完马上释放 S 锁。**防止修改时读取**,可解决 **丢失修改** 和 **读脏数据** 问题,因为一个事务在对数据 A 进行修改,根据 1 级封锁协议,会加 X 锁,那么就不能再加 S 锁了,也就是不会读入数据。

三级封锁协议:在二级的基础上,要求读取数据 A 时必须加 S 锁,直到事务结束了才能释放 S 锁。**防止读取时修改**,可解决 **丢失修改** 和 **读脏数据** 问题,还进一步防止了 **不可重复读** 的问题,因为读 A 时,其它事务不能对 A 加 X 锁,从而避免了在读的期间数据发生改变。

两段锁协议

两段锁协议是指每个事务的执行可以分为两个阶段: **生长阶段 (加锁阶段) 和衰退阶段 (解锁阶段)。** 两段封锁法可以这样来实现:

事务开始后就处于加锁阶段,一直到执行 ROLLBACK 和 COMMIT 之前都是加锁阶段。
ROLLBACK 和 COMMIT 使事务进入解锁阶段,即在 ROLLBACK 和 COMMIT 模块中 DBMS 释放所有封锁。

4关系数据库设计理论

4.1函数依赖

- 记 $A \to B$ 表示 A 函数决定 B,也可以说 B 函数依赖于 A。
- 若 $\{A_1, A_2, ..., A_n\}$ 是关系的一个或多个属性的集合,该集合函数决定了关系的其它所>有属性并且是 最小的 ,那么该集合就称为 键码 。
- 对于 $A \to B$,如果能找到 A 的真子集 A',使得 $A' \to B$,那么 $A \to B$ 就是 部分函数>依赖, 否则就是 完全函数依赖。
- 对于 $A \to B$, $B \to C$, 则 $A \to C$ 是一个 传递函数依赖。

4.2异常

• 如表所示,展示了学生课程关系的函数依赖为 {Sno, Cname} -> {Sname, Sdept, Mname, Grade}, 键码为 {Sno, Cname}。也就是说,确定学生和课程后就能确定其它信息。

Sno	Sname	Sdept	Mname	Cname	Grade
1	学生-1	学院-1	院长-1	课程-1	90
2	学生-2	学院-2	院长-2	课程-2	80
2	学生-2	学院-2	院长-2	课程-1	100
3	学生-3	学院-2	院长-2	课程-2	95

不符合范式的关系,会产生很多异常,主要有以下四种异常:

冗余数据:例如 学生-2 出现了两次。

修改异常:修改了一个记录中的信息,但是另一个记录中相同的信息却没有被修改。

删除异常: 删除一个信息,那么也会丢失其它信息。例如删除了课程-1需要删除第一>行和第三行,那

么 学生-1 的信息就会丢失。

插入异常:例如想要插入一个学生的信息,如果这个学生还没选课,那么就无法插入。

4.3范式

范式理论是为了解决以上提到四种异常。**高级别范式的依赖于低级别的范式**,1NF 是最低级别的范式。

4.4第一范式 (1NF)

属性不可分。即数据库表的**每一列**都是不可分割的**基本数据项**,同一列中不能有多个值,即实体中的某个属性不能有多个值或者不能有重复的属性。

4.5第二范式 (2NF)

每个非主属性完全函数依赖于键码。可以通过分解来满足 2NF。

分解前:

Sno	Sname	Sdept	Mname	Cname	Grade
1	学生-1	学院-1	院长-1	课程-1	90
2	学生-2	学院-2	院长-2	课程-2	80
2	学生-2	学院-2	院长-2	课程-1	100
3	学生-3	学院-2	院长-2	课程-2	95

以下学生课程关系中, {Sno, Cname} 为键码, 有如下函数依赖:

- Sno -> Sname, Sdept
- Sdept -> Mname
- Sno, Cname-> Grade

函数依赖状况分析:

Grade 完全函数依赖于键码,它没有任何冗余数据,每个学生的每门课都有特定的成绩。 Sname, Sdept 和 Mname 都部分依赖于键码,当一个学生选修了多门课时,这些数据就会出现 多次,造成大量冗余数据。

分解后:

关系-1:

Sno	Sname	Sdept	Mname
1	学生-1	学院-1	院长-1
2	学生-2	学院-2	院长-2
3	学生-3	学院-2	院长-2

- 有以下函数依赖:
 - Sno -> Sname, Sdept
 - Sdept -> Mname

• 关系-2:

Sno	Cname	Grade
1	课程-1	90
2	课程-2	80
2	课程-1	100
3	课程-2	95

• 有以下函数依赖: Sno, Cname ightarrow Grade

4.6第三范式 (3NF)

非主属性不传递函数依赖于键码。简而言之,第三范式就是属性不依赖于其它非主属性。

• 上面的 关系-1 中存在以下传递函数依赖: Sno o Sdept o Mname.

• 关系-1.1:

Sno	Sname	Sdept
1	学生-1	学院-1
2	学生-2	学院-2
3	学生-3	学院-2

• 关系-1.2:

Sdept	Mname
学院-1	院长-1
学院-2	院长-2

4.7巴斯-科德范式 (BCNF)

Boyce-Codd Normal Form (巴斯-科德范式)

在3NF基础上,任何非主属性不能对主键子集依赖(在3NF基础上消除对主码子集的依赖)

巴斯-科德范式 (BCNF) 是第三范式 (3NF) 的一个子集,即满足巴斯-科德范式 (BCNF) 必须满足第三范式 (3NF)。通常情况下,巴斯-科德范式被认为没有新的设计规范加入,只是对第二范式与第三范式中设计规范要求更强,因而被认为是修正第三范式,也就是说,它事实上是对**第三范式的修正**,使数据库冗余度更小。这也是BCNF不被称为第四范式的原因。某些书上,根据范式要求的递增性将其称之为第四范式是不规范,也是更让人不容易理解的地方。而真正的第四范式,则是在设计规范中添加了对多值及依赖的要求。

5.ER 图

实体关系图 (Entity-Relationship, E-R),有三个组成部分:**实体、属性、联系**。用来进行关系型数据库系统的概念设计。

- 实体: 用矩形表示, 矩形框内写明实体名.
- 属性: 用椭圆形表示, 并用无向边将其与相应的实体连接起来。
- **联系**:用菱形表示,菱形框内写明联系名,并用无向边分别与有关实体连接起来,同时在无向边旁标上联系的类型 (1...1, 1...* 或 ...)就是指存在的**三种关系** (一对一、一对多或多对多)。

ER 模型转换为关系模式的原则:

- 一对一:遇到一对一关系的话,在两个实体任选一个添加另一个实体的主键即可。
- **一对多**:遇到一对多关系的话,在**多端添加另一端**的主键。
- **多对多**:遇到多对多关系的话,我们需要将**联系转换为实体**,然后在该**实体上加上另外两个实体的主键**,作为联系实体的主键,然后再加上该联系自身带的属性即可。

6.索引

6.1索引的数据结构

B-Tree (平衡树, Balance Tree): 也称为 **多路平衡查找树**,并且所有叶子节点位于同一层。

B+Tree:它不仅具有 B-Tree 的平衡性,并且可通过 顺序访问指针 来提高 区间查询 的性能。在 B+Tree 中,一个节点中的 key 从左到右非递减排列,若某个指针的 key_i 左右相邻分别是 key_{i-1} 和 key_{i+1} ,且不为 null,则该指针指向节点的所有 key 满足 $key_{i-1} \le key_i \le key_{i+1}$

B+Tree 与 B-Tree 最大区别是,B+Tree 的非叶子结点不保存数据,只用于索引,所有数据都保存在叶子结点中。而且叶子结点间按照从小到大顺序链接起来。

B-Tree/B+Tree 的增删改查:

查找操作: 首先在**根节点**进行 **二分查找**,找到一个 key 所在的指针,然后递归地在指针所指向的节点进行查找。直到查找到叶子节点,然后在 **叶子节点** 上进行 **二分查找**,找出 key 所对应的 data。

二分查找要求表有序,正好 B-Tree 和 B+Tree 结点中的 key 从左到右非递减有序排列。

增删操作:会破坏平衡树的平衡性,因此在插入删除操作之后,需要对树进行一个分裂、合并、旋转等操作来维护平衡性。

6.2MySQL 索引

索引,在 MySQL 也称为键 (Key),是 **存储引擎** 快速找到记录的一种 **数据结构**。相当于图书的目录,可根据目录中的页码快速找到所需的内容。

6.3索引结构类型

(1) B+Tree 索引

B+Tree 索引是大多数 MySQL 存储引擎的默认索引类型。

因为 B+ Tree 的 **有序性**,因此可用于 部**分查找、范围查找、排序 和 分组**。

适用于全键值、键值范围和键前缀查找,其中键前缀查找只适用于最左前缀查找。若不是按照索引列的顺序进行查找,则无法使用索引。

(2) Hash 索引

Hash 索引能以 O(1) 时间进行查找,但是失去了有序性。因此无法用于排序与分组,无法用于部分查找和范围查找,只支持 **精确查找**。

Hash 索引仅满足 =, IN 和 <=> 查询,不能使用范围查询。因为 Hash 索引比较的是 Hash 运算后的 Hash 值,所以它只能用于等值的过滤。

(3) 全文索引

全文索引使用**倒排索引**实现,它记录着**关键词到其所在文档**的映射。

(4) 空间数据索引

- 空间数据索引会从所有维度来索引数据,可以有效地使用任意维度来进行组合查询。
- 必须使用 GIS 相关的函数来维护数据。

6.4索引的优点缺点

优点

- 大大减少了服务器需要扫描的数据行数。
- 避免服务器进行排序和分组操作,以避免创建 **临时表**。

B+Tree 索引是有序的,可以用于 ORDER BY 和 GROUP BY 操作。临时表主要是在排序和分组过程中创建,不需要排序和分组,也就不需要创建临时表。

将随机 I/O 变为 顺序 I/O。

B+Tree 索引是有序的,会将相邻的数据都存储在一起。

缺点

• 索引并不是越多越好,索引固然可以提高相应的 SELECT 的效率,但同时也降低了 INSERT 及 UPDATE 的效率,因为 INSERT 或 UPDATE 时有可能会 **重建索引**。

6.5索引的设计原则

从索引的优、缺点考虑索引的设计原则。

- 忌过度索引:索引需要额外的磁盘空间,而且会降低写操作的性能。
 - 在修改表内容时,索引会进行更新甚至重构,索引列越多花销时间越长。为此优化检索性能,只保持需要的索引即可。
 - 经常用在 **排列、分组 和 范围搜索** 的列适合创建索引,因为索引是有序的。
 - 。 经常出现在 WHERE 子句的列,或是 JOIN 连接子句中指定的列适合创建索引。
- 使用短索引: 若对长字符串列进行索引,应该指定一个前缀长度,这样能够节省大量索引空间。

6.6索引的优化策略

- 独立的列:在进行查询时,索引列不能是 表达式 的一部分,也不能是 函数参数,否则无法使用索引。
- 多列索引:在需要使用多个列作为条件进行查询时,使用多列索引比使用多个单列索引性能更好。
- **索引列的顺序**:让选择性**最强**的索引列放在**前面**。
- **前缀索引**:对于 BLOB、TEXT 和 VARCHAR 类型的列,必须使用前缀索引,只索引开始的部分字符。前缀长度的选取需要根据索引选择性来确定。
- 覆盖索引:索引包含所有需要查询的字段的值。具有以下优点:
 - 索引通常远小于数据行的大小,只读取索引能大大减少数据访问量。
 - 一些存储引擎(例如 MyISAM)在内存中只缓存索引,而数据依赖于操作系统来缓存。因此,只访问索引可以不使用系统调用(通常比较费时)。

6.7索引的使用场景

- 对于 **非常小的表**:大部分情况下简单的 **全表扫描** 比建立索引更高效;
- 对于 中大型的表: 建立索引 非常有效;
- 对于 **特大型的表**:建立和维护索引的代价将会随之增长。这种情况下,需要用到一种技术可以直接区分出需要查询的一组数据,而不是一条记录一条记录地匹配。例如可以使用**分区技术**。